

See discussions, stats, and author profiles for this publication at: <https://www.researchgate.net/publication/270823875>

# A-1 ANALISIS SENTIMEN DAN KLASIFIKASI KATEGORI TERHADAP TOKOH PUBLIK PADA TWITTER

Conference Paper · August 2013

---

CITATIONS

0

---

READS

891

10 authors, including:



[Ahmad Fathan Hidayatullah](#)

Universitas Islam Indonesia

5 PUBLICATIONS 1 CITATION

SEE PROFILE

## ANALISIS SENTIMEN DAN KLASIFIKASI KATEGORI TERHADAP TOKOH PUBLIK PADA TWITTER

Ahmad Fathan Hidayatullah<sup>1)</sup>, Azhari SN<sup>2)</sup>

<sup>1)</sup>Jurusan Teknik Informatika Fakultas Teknologi Industri,  
Universitas Islam Indonesia  
e-mail : [fathanel@gmail.com](mailto:fathanel@gmail.com)

<sup>2)</sup> Jurusan Ilmu Komputer dan Elektronika, Fakultas Matematika  
dan Ilmu Pengetahuan Alam, Universitas Gadjah Mada  
e-mail : [arism@ugm.ac.id](mailto:arism@ugm.ac.id)

### Abstrak

Keberadaan Twitter telah digunakan secara luas oleh berbagai lapisan masyarakat dalam beberapa tahun terakhir. Kebiasaan masyarakat mem-posting tweet untuk menilai tokoh publik adalah salah satu media yang merepresentasikan tanggapan masyarakat terhadap tokoh publik. Menjelang pemilihan umum, biasanya ada pihak-pihak tertentu yang ingin mengetahui sentimen dan tanggapan terhadap tokoh publik. Tokoh publik yang dinilai adalah tokoh yang dianggap layak dan memiliki kemampuan untuk dipilih menjadi pemimpin. Oleh karena itu, penelitian ini mencoba menganalisis tweet berbahasa Indonesia yang membicarakan tentang tokoh publik. Analisis dilakukan dengan melakukan klasifikasi tweet yang berisi sentimen masyarakat tentang tokoh tertentu. Metode klasifikasi yang digunakan dalam penelitian ini adalah Naive Bayes Classifier. Naive Bayes Classifier dikombinasikan dengan fitur untuk dapat mendeteksi negasi dan pembobotan menggunakan term frequency serta TF-IDF. Klasifikasi tweet pada penelitian ini diperoleh berdasarkan kombinasi antara kelas sentimen dan kelas kategori. Klasifikasi sentimen terdiri dari positif dan negatif sedangkan klasifikasi kategori terdiri dari kapabilitas, integritas, dan akseptabilitas. Hasil pengujian pada aplikasi yang dibangun dan pada tools RapidMiner memperlihatkan bahwa akurasi dengan term frequency memberikan hasil akurasi yang lebih baik daripada akurasi dengan fitur TF-IDF. Metode Support Vector Machine menghasilkan akurasi performansi yang lebih baik daripada metode Naive Bayes baik dalam klasifikasi sentimen maupun dalam klasifikasi kategori. Namun demikian, secara keseluruhan penggunaan metode Support Vector Machine dan Naive Bayes sama-sama memiliki performansi yang cukup baik untuk melakukan klasifikasi tweet.

**Kata Kunci :** Analisis sentimen, Klasifikasi kategori, Naive Bayes , Support Vector Machine

### 1. PENDAHULUAN

Media jejaring sosial seperti Twitter, Facebook, dan Youtube merupakan beberapa media perangkat komunikasi terpopuler di masyarakat saat ini (Aliandu, 2012; Kumar dan Sebastian, 2012). Menjelang pemilihan umum, para politisi atau tokoh publik sering memanfaatkan media sosial untuk berkampanye dan meningkatkan popularitas mereka. Salah satu media jejaring sosial yang telah dimanfaatkan dalam pemilihan umum adalah Twitter. Twitter telah dimanfaatkan dalam pemilihan umum di beberapa negara seperti Singapura, Jerman, dan Amerika (Sang dan Bos, 2012; Choy dkk, 2012; Choy dkk, 2011).

Penelitian ini mencoba memanfaatkan Twitter dengan menganalisis *tweet* berbahasa Indonesia yang membicarakan tentang tokoh publik menjelang pemilihan umum 2014 di Indonesia. Tokoh publik yang dianalisis merupakan tokoh publik dengan popularitas tertinggi hasil survei yang telah dilakukan dari beberapa lembaga survei seperti Lembaga Survei Indonesia (LSI), Lembaga Survei Nasional (LSN), Sogeng Sarjadi Syndicate (SSS), Centre for Strategic and International Studies (CSIS) dan Saiful Mujani Research and Consulting (SMRC). Analisis dilakukan dengan mengklasifikasikan *tweet* menggunakan Naive Bayes Classifier. Naive Bayes Classifier dikombinasikan dengan fitur untuk dapat mendeteksi negasi dan pembobotan menggunakan term frequency serta TF-IDF.

Klasifikasi *tweet* pada penelitian ini diperoleh berdasarkan kombinasi antara kelas sentimen dan kelas kategori. Kelas sentimen terbagi menjadi dua polaritas yaitu sentimen positif dan negatif. Kelas kategori dipilih berdasarkan indikator yang telah digunakan oleh LSI (Lembaga Survei Indonesia) untuk menilai tokoh yang dianggap layak maju dalam pilpres 2014. Ketiga dimensi tersebut adalah kapabilitas, integritas, dan akseptabilitas. Dimensi kapabilitas mencakup kepandaian, wawasan, visi, kepemimpinan, ketegasan, dan keberanian dalam pengambilan keputusan. Integritas mencakup aspek moral, kejujuran, satu dalam kata dan perbuatan, serta bersih dari cacat moral, etik, dan hukum. Akseptabilitas adalah sikap penerimaan masyarakat terhadap seorang tokoh (Mujani, dkk, 2012).

## 2. TINJAUAN PUSTAKA

Sunni dan Widyantoro (2012) telah melakukan analisis sentimen pada Twitter untuk mengetahui opini atau sentimen terhadap tokoh publik dari *tweet* berbahasa Indonesia. Penelitian ini menggunakan F3 (*F3 is Factor Finder*) untuk menangani permasalahan model bahasa yang ditemukan. F3 menggunakan metode *Naive Bayes* untuk melakukan analisis sentimen. Fitur TF-IDF dengan *discounted-cumulative* digunakan untuk menangani karakter topik yang muncul di Twitter yang berkelanjutan. Penggunaan TF-IDF dengan *discounted cumulative* untuk mengekstrak topik mampu meningkatkan jumlah topik terekstrak yang sesuai.

*Naive Bayes* juga digunakan oleh Aliandu (2012) untuk menentukan sentimen publik yang disampaikan melalui *tweet* berbahasa Indonesia. Penelitian ini menggunakan *term* objek tertentu hasil *query user*. Data yang terkumpul akan mengalami *preprocessing* sebelum dilakukan proses *training*. Data *training* dikumpulkan dengan memanfaatkan fasilitas *crontab* dengan *query emoticon* dan akun media nasional yang terhubung ke Twitter API. Penelitian ini menggunakan *emoticon* untuk memudahkan melakukan anotasi terhadap kelas sentimen dari data *training*. *Emoticon* dianggap dapat menunjukkan emosi *tweet* yang disampaikan. Setelah itu, *Naive Bayes Classifier* digunakan untuk klasifikasi sentimen dari data *tweet* yang telah diperoleh.

Penelitian lain menggunakan algoritma *Naive Bayes* juga dilakukan oleh Groot (2012). Selain *Naive Bayes*, penelitian ini juga menggunakan *Support Vector Machine* untuk membuat model prediksi klasifikasi opini data Twitter. Dalam penelitian tersebut, data opini yang berasal dari data *tweet* diklasifikasi menjadi tiga buah kelas yaitu kelas positif, negatif, dan netral. *Preprocessing* dilakukan terlebih dahulu terhadap data sebelum pembuatan model prediksi. *Preprocessing* dilakukan untuk mengubah data teks menjadi *fixed-length feature vector*. Fitur penelitian ini terdiri dari *sentiment-words* dan frekuensi kemunculan kata yang digunakan untuk memprediksi kelas sentimen.

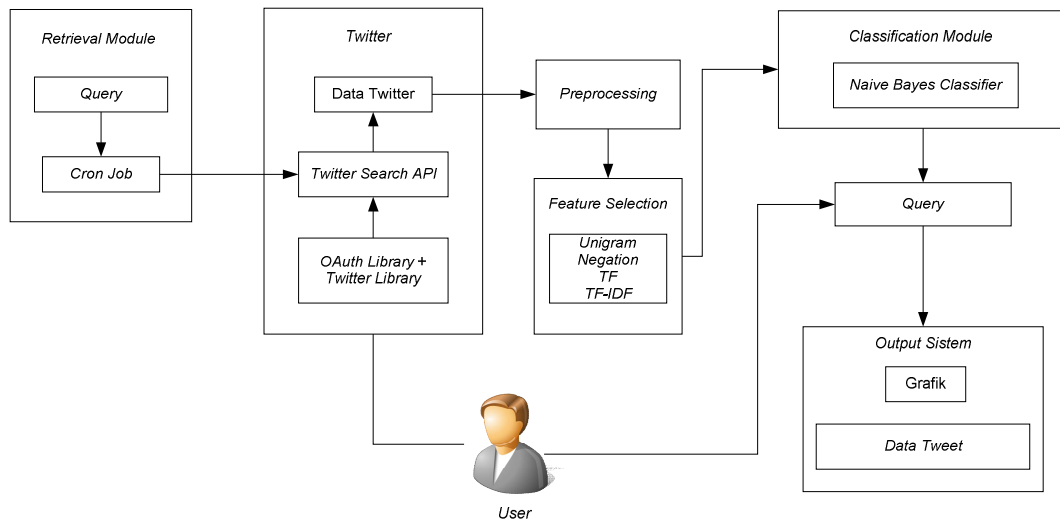
Romelta (2012) juga menggunakan dua buah algoritma pembelajaran yaitu *Support Vector Machine* dan *Naive Bayes* untuk menggali opini *customer* terhadap produk *smartphone* di Twitter. Penelitian ini mencoba membangun sistem pembelajaran mesin untuk mengklasifikasikan opini berdasarkan sentimennya. Sistem mengekstraksi kata menggunakan *n-multigram* pada tahap ekstraksi fitur. Tiga buah percobaan dilakukan untuk mendapatkan sebuah pembelajaran mesin yang memiliki akurasi terbaik. Hasil percobaan menyimpulkan bahwa SVM dengan pemrosesan *casefolding*, normalisasi Twitter, *POS tagger*, tokenisasi produk dan ekstraksi fitur *1-gram* memiliki akurasi yang terbaik sebesar 70%. Hal ini lebih baik dibandingkan tanpa pemrosesan awal dimana akurasi yang dicapai adalah 63.9%.

Berdasar penelitian yang telah ada sebelumnya, penelitian ini mencoba melakukan klasifikasi *tweet* berdasarkan sentimen dan kategori yang berasal dari fitur yang dimiliki oleh tokoh publik. Berdasarkan kombinasi kelas sentimen dan kategori, penelitian ini akan mengklasifikasikan *tweet* menjadi enam kelas yaitu *tweet* yang membicarakan tentang kapabilitas-positif, kapabilitas-negatif, integritas-positif, integritas-negatif, akseptabilitas-positif, dan akseptabilitas-negatif. Klasifikasi *tweet* dilakukan menggunakan metode *Naive Bayes Classifier*. Model klasifikasi pada penelitian ini menambahkan fitur untuk dapat mendeteksi negasi yang terdapat dalam *tweet*. Ekstraksi fitur pada penelitian ini menggunakan fitur *unigram*. Model klasifikasi dan pembobotan kata (*term weighting*) dihitung menggunakan *term frequency (laplace smoothing)* serta TF-IDF (*term frequency inverse document frequency*).

## 3. METODE PENELITIAN

### 3.1 Rancangan Sistem

Rancangan sistem yang akan dibangun dalam penelitian terbagi menjadi beberapa bagian diantaranya *retrieval module*, *preprocessing*, *feature selection*, dan *classification module*. Gambar 1 memperlihatkan sistem yang dibangun secara lebih rinci. Bagian sistem yang berinteraksi dengan pengguna aplikasi secara langsung akan memberikan pilihan kepada *user* untuk memilih salah satu dari nama tokoh publik sebagai *query*. *Query* akan memberikan hasil berupa grafik tokoh yang menggambarkan berapa banyak tanggapan positif dan negatif. Selain itu, dapat diketahui pula konten *tweet* yang dicari apakah berbicara tentang integritas, kapabilitas, atau kapabilitas yang bernilai positif atau negatif dari tokoh tersebut.



Gambar 1 Rancangan Sistem

### 3.1.1 Retrieval Module

*Tweet* dikumpulkan dengan memanfaatkan fasilitas *cron job* di sistem operasi *Windows*. *Query* untuk mendapatkan data *tweet* berasal dari kombinasi nama tokoh dengan kata dalam kamus yang telah dikelompokkan berdasarkan sentimen dan kategorinya. Proses pencarian *tweet* dilakukan secara berkala dengan bantuan *Twitter Search API* v1.1. Proses autentikasi dan akses data ke Twitter diperoleh dengan memanfaatkan *library OAuth* yang merupakan suatu *authorization framework*. *Library* lain yang digunakan dalam sistem ini adalah *library Twitter* yang bertugas mengirimkan pesan kepada Twitter dan menerima status *update*.

### 3.2.1 Preprocessing

*Preprocessing* dilakukan untuk menghindari data yang kurang sempurna, gangguan pada data, dan data-data yang tidak konsisten (Hemalatha, dkk, 2012). Tahapan *text preprocessing* pada penelitian ini diantaranya :

1. Menghapus URL  
URL (<http://www.situs.com>) dan email ([nama@situs.com](mailto:nama@situs.com)) dihapus di tahapan ini.
2. Mengganti Emoticon  
Proses convert emoticon mengganti emoticon yang terdapat pada tweet dengan kata yang mencerminkan emoticon. Daftar konversi emoticon dapat dilihat pada Tabel 1.

Tabel 1 Konversi Emoticon

Emoticon	Konversi
:) :-) :) :-)) =) =))	Senyum
:D :-D =D	Tawa
:-( :(	Sedih
;-) ;)	Kedip
:-P :P	Ejek
:-/ :/	Ragu
:  :-	Haru

3. Menghapus Karakter Khusus Twitter  
Proses ini dilakukan dengan menghapus karakter khusus Twitter seperti *hashtag* (#*hashtag*), *username* (@*username*), dan karakter khusus (misal : RT, yang menunjukkan bahwa *user* melakukan *retweet*).
4. Menghapus Simbol  
Tahapan ini dilakukan untuk membuang simbol dan tanda baca dalam *tweet*.
5. Tokenisasi  
Tokenisasi yaitu tahap pemotongan string input berdasarkan kata yang menyusunnya (Nugroho, 2011).
6. Cek Nama Tokoh  
Proses pengecekan nama tokoh dilakukan untuk mengecek keberadaan nama tokoh pada *tweet* dimana nama tersebut terdapat dalam daftar kamus.
7. *Case folding*  
Proses *case folding* menyeragamkan bentuk huruf menjadi huruf besar atau huruf kecil.
8. Mengganti Kata Tidak Baku (*Slangword*)  
Proses ini mengganti kata-kata dalam *tweet* yang tidak baku menjadi kata baku yang telah dikenal dalam bahasa Indonesia.

9. *Stemming*  
*Stemming* adalah tahap mencari akar kata dengan menghilangkan imbuhan pada sebuah kata.
10. Membuang *Stopword*  
*Stopword* merupakan kata-kata yang tidak berpengaruh terhadap proses klasifikasi.
11. Menggabungkan Kata Negasi  
Proses ini dilakukan untuk mendeteksi negasi yang terdapat dalam *tweet*.

### 3.3.1 Pemilihan dan Ekstraksi Fitur

Proses pemilihan dan ekstraksi fitur yang digunakan dalam penelitian ini diantaranya :

1. *Unigram*  
*Unigram feature extractor* merupakan cara paling sederhana dalam mendapatkan fitur dari *tweet* (Go, dkk, 2009). Proses ekstraksi *unigram* dilakukan dengan mengekstrak kata per kata dalam dokumen. Model *unigram* digambarkan dengan persamaan (3.1)
2. *Negation*  
Negasi merupakan sesuatu yang dikenal dalam semua bahasa dan biasanya negasi digunakan untuk mengubah polaritas dari suatu pernyataan (Blanco dan Moldovan, 2011).
3. *Term Frequency (Laplace Smoothing)*  
*Term frequency* adalah gagasan standar frekuensi dalam *corpus-based* pengolahan bahasa alami (Yamamoto dan Church, 2001).
4. *TF-IDF (Term Frequency-Inverse Document Frequency)*  
Pembobotan TF-IDF memberikan bobot pada *term t* dalam dokumen *d* ditunjukkan oleh persamaan (3.2) (Manning, dkk, 2009).

$$P_{uni}(t_1 t_2 t_3 t_4) = P(t_1)P(t_2)P(t_3)P(t_4) \quad (3.1)$$

$$tf - idf_{t,d} = tf_{t,d} \times idf_t \quad (3.2)$$

Nilai  $tf_{t,d}$  merupakan bobot suatu *term t* pada dokumen *d* sedangkan  $idf_t$  adalah *inverse document frequency* dari *term t*. Persamaan (3.3) adalah persamaan untuk mencari nilai  $idf_t$ . Nilai  $idf_t$  diperoleh dari hasil logaritma  $N$  dibagi dengan  $df_t$ .  $N$  merupakan jumlah dokumen keseluruhan sedangkan  $df_t$  adalah banyaknya dokumen yang memuat *term t*.

$$idf_t = \log \frac{N}{df_t} \quad (3.3)$$

### 3.4.1 Classification Module

Klasifikasi menggunakan *Naive Bayes Classifier* dan *term frequency* dilakukan berdasar persamaan (3.4).

$$c_{map} = \underset{c \in C}{argmax} \hat{P}(c|d) = \underset{c \in C}{argmax} \hat{P}(c) \prod_{1 \leq k \leq n_d} \hat{P}(t_k|c) \quad (3.4)$$

Nilai  $\hat{P}(c)$  dan  $\hat{P}(t_k|c)$  diperoleh dari data pelatihan sedangkan nilai  $\hat{P}(c)$  untuk fitur *term frequency* diperoleh dari persamaan (3.5).

$$\hat{P}(c) = \frac{N_c}{N'} \quad (3.5)$$

Nilai  $N_c$  pada persamaan (3.5) mewakili jumlah dokumen dalam kelas *c* dan  $N'$  adalah jumlah dokumen keseluruhan dalam data pelatihan. Perhitungan probabilitas kondisional frekuensi relatif *term t* dalam dokumen kelas *c* atau  $\hat{P}(t_k|c)$  dihitung menggunakan persamaan (3.6) (Manning, dkk, 2009).

$$\hat{P}(t|c) = \frac{T_{ct} + 1}{\sum_{t' \in V} (T_{ct'} + 1)} = \frac{T_{ct} + 1}{(\sum_{t' \in V} T_{ct'}) + B'} \quad (3.6)$$

Nilai  $T_{ct}$  pada persamaan merupakan jumlah kemunculan suatu *term* dalam dokumen pada kelas *c* dalam data pelatihan.  $T_{ct'}$  adalah jumlah kemunculan semua *term* pada kelas *c* dalam data pelatihan. Nilai  $B'$  pada persamaan di atas merupakan jumlah *term* dalam *vocabulary*.

Klasifikasi dengan *Naive Bayes Classifier* dan TF-IDF dilakukan berdasarkan persamaan (3.7).

$$c_{map} = \underset{c \in C}{argmax} [\log \hat{P}(c) + \sum_{n f_{ni}} \log \hat{P}(t_k|c)] \quad (3.7)$$

Nilai *prior*  $\log \hat{P}(c)$  adalah bobot yang menunjukkan frekuensi relatif kelas *c*. Probabilitas *prior* untuk fitur TF-IDF diperoleh melalui persamaan (3.8).

$$\hat{P}(c) = \log \frac{N_c}{N'} \quad (3.8)$$

Nilai  $\log \hat{P}(t_k|c)$  diperoleh dari persamaan (3.9).

$$\hat{P}(t|c) = \log \frac{T_{ct} + 1}{(\sum_{t' \in V} T_{ct'}) + B'} \quad (3.9)$$

## 3.2 Metode Evaluasi dan Model Klasifikasi

Metode evaluasi model klasifikasi yang digunakan pada penelitian ini adalah *Holdout* dimana sebanyak setengah atau dua per tiga dari data keseluruhan untuk keperluan proses *training* sedangkan sisanya digunakan untuk keperluan *testing* (Kantardzic, 2003). Metode lain yang digunakan untuk evaluasi adalah *confusion matrix*. *Confusion matrix* merupakan salah satu *tools* penting dalam metode visualisasi yang digunakan pada mesin pembelajaran yang biasanya memuat dua kategori atau lebih (Manning, dkk, 2009; Horn, 2010). Tabel 2 menggambarkan contoh hasil *confusion matrix* prediksi dua kelas.

Tabel 2 Contoh Hasil Confusion Matrix Prediksi Dua Kelas

		Actual Class	
		Class-1	Class-2
Predicted Class	Class-1	True positive	False negative
	Class-2	False positive	True negative

Nilai *true positive* (TP) dan *true negative* (TN) adalah hasil klasifikasi yang benar. Nilai *false positive* (FP) adalah nilai dimana hasilnya diprediksi sebagai *class-1* namun sebenarnya merupakan *class-2* sedangkan *false negative* (FN) adalah nilai dimana prediksi mengklasifikasikan sebagai *class-2* namun faktanya termasuk dalam klasifikasi *class-1*. Nilai akurasi *confusion matrix* berdasarkan Tabel 2 diperoleh dengan persamaan (3.10).

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.10)$$

#### 4. HASIL DAN PEMBAHASAN

##### 4.1 Perhitungan Akurasi Classifier pada Aplikasi

Sebanyak 1329 data *tweet* hasil pencarian dilabeli secara manual untuk diklasifikasikan dengan *Naive Bayes*. Proses pengujian dimulai dengan tahap *preprocessing* untuk membersihkan *tweet* dan menyiapkan *tweet* untuk proses klasifikasi. Proses dilanjutkan dengan menghitung probabilitas masing-masing kata dalam *tweet* berdasarkan data *training* menggunakan fitur *term frequency* dan fitur TF-IDF.

Hasil pengujian klasifikasi *tweet* ditunjukkan oleh Gambar 2. Akurasi pengujian klasifikasi dengan fitur *term frequency* diperoleh sebesar 70,88%. Pengujian klasifikasi dengan fitur TF-IDF didapatkan sebesar 69,30%. Berdasarkan hasil tersebut diketahui bahwa penggunaan fitur *term frequency* menghasilkan performansi dengan akurasi lebih baik sebesar 1,58% daripada klasifikasi kategori dengan fitur TF-IDF.

Hasil Klasifikasi Label dengan Fitur Term Frequency

Term Frequency	true integritas-negatif	true akseptabilitas-positif	true integritas-positif	true kapabilitas-negatif	true akseptabilitas-negatif	true kapabilitas-positif
pred. integritas-negatif	38	2	5	1	3	16
pred. akseptabilitas-positif	2	80	8	0	1	16
pred. integritas-positif	0	3	35	0	0	14
pred. kapabilitas-negatif	0	2	0	38	3	15
pred. akseptabilitas-negatif	1	2	2	2	62	12
pred. kapabilitas-positif	0	2	16	1	0	61

Akurasi dengan fitur *term frequency* = 70.88%

Hasil Klasifikasi Label dengan Fitur TF-IDF

TF-IDF	true integritas-negatif	true akseptabilitas-positif	true integritas-positif	true kapabilitas-negatif	true akseptabilitas-negatif	true kapabilitas-positif
pred. integritas-negatif	36	13	10	1	4	1
pred. akseptabilitas-positif	0	93	13	0	0	1
pred. integritas-positif	2	8	42	0	0	0
pred. kapabilitas-negatif	0	11	2	39	2	4
pred. akseptabilitas-negatif	0	21	7	2	50	1
pred. kapabilitas-positif	0	17	16	0	0	47

Akurasi dengan fitur TF-IDF = 69.30%

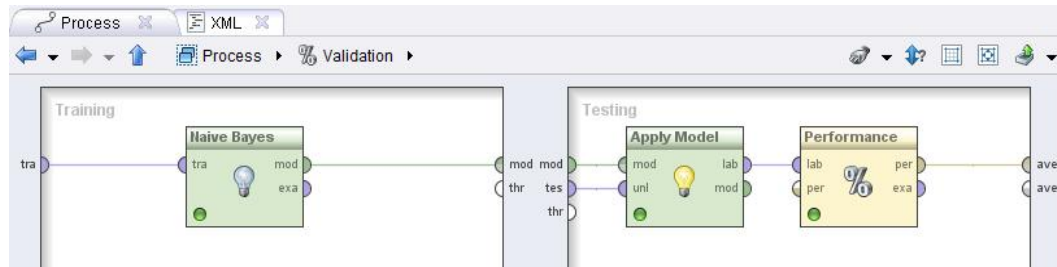
Gambar 2 Printscreen Hasil Akurasi Pada Aplikasi

##### 4.2 Perhitungan Akurasi dengan RapidMiner

Hasil akurasi yang diperoleh dari aplikasi akan dibandingkan dengan hasil perhitungan akurasi menggunakan *tools* RapidMiner versi 5.2.008. Perhitungan akurasi menggunakan RapidMiner dilakukan dengan metode *Naive Bayes* dan *Support Vector Machine*.

##### 4.2.1 Perhitungan Akurasi dengan Naive Bayes pada RapidMiner

Gambar 3 memperlihatkan proses *training* dan *testing* untuk menghitung akurasi dengan metode *Naive Bayes* pada RapidMiner. Tahapan ini mengaplikasikan model dari data *training* ke dalam data *testing* menggunakan operator *apply model* dan melakukan evaluasi dengan operator *performance*.



Gambar 3 Proses *Training* dan *Testing* dengan *Naive Bayes*

Perhitungan akurasi klasifikasi menggunakan metode *Naive bayes* dengan fitur *term frequency* diperoleh sebesar 73,81%. Gambar 4 merupakan *table view* yang memperlihatkan *performance vector* pada RapidMiner.

accuracy: 73.81%						
	true kapabilitas-positif	true integritas-positif	true integritas-negatif	true kapabilitas-negati	true akseptabilitas-po	true akseptabilitas-neg
pred. kapabilitas-posit	67	11	4	6	5	2
pred. integritas-positif	7	28	5	1	5	1
pred. integritas-negatif	1	1	38	1	2	1
pred. kapabilitas-nega	4	3	3	44	4	7
pred. akseptabilitas-po	1	9	2	1	81	1
pred. akseptabilitas-n	0	0	13	5	10	69

Gambar 4 Akurasi dengan Metode *Naive Bayes* dan Fitur *Term Frequency* pada RapidMiner


Hasil perhitungan akurasi klasifikasi dengan metode *Naive Bayes* dan fitur TF-IDF diperlihatkan pada Gambar 5. Tabel *view* performansi pada RapidMiner menunjukkan bahwa akurasi diperoleh sebesar 71.11%.

accuracy: 71.11%						
	true kapabilitas-positif	true integritas-positif	true integritas-negatif	true kapabilitas-negati	true akseptabilitas-po	true akseptabilitas-neg
pred. kapabilitas-posit	63	11	4	5	12	2
pred. integritas-positif	8	27	6	2	7	2
pred. integritas-negatif	2	1	40	1	3	3
pred. kapabilitas-nega	2	2	1	41	5	3
pred. akseptabilitas-po	3	9	3	1	75	2
pred. akseptabilitas-n	2	2	11	8	5	69

Gambar 5 Akurasi dengan Metode *Naive Bayes* dan fitur TF-IDF pada RapidMiner

#### 4.2.2 Perhitungan Akurasi dengan Support Vector Machine pada RapidMiner

Proses *training* dan *testing* metode *Support Vector Machine* diperlihatkan oleh Gambar 6. Operator pada proses *training* yang digunakan pada perhitungan akurasi ini adalah LibSVM.



Gambar 6 Proses *Training* dan *Testing* dengan *Support Vector Machine* pada RapidMiner

Hasil perhitungan klasifikasi menggunakan metode *Support Vector Machine* dan fitur *term frequency* diperoleh sebesar 83,14% sebagaimana diperlihatkan pada Gambar 7.



accuracy: 83.14%						
	true kapabilitas-positif	true integritas-positif	true integritas-negatif	true kapabilitas-negatif	true akseptabilitas-po	true akseptabilitas-neg
pred. kapabilitas-positif	67	1	0	3	2	0
pred. integritas-positif	4	36	4	1	4	1
pred. integritas-negatif	4	6	51	5	1	4
pred. kapabilitas-nega	2	1	2	43	0	2
pred. akseptabilitas-pr	3	5	1	3	97	3
pred. akseptabilitas-ni	0	1	6	2	3	71

Gambar 7 Akurasi dengan Metode *Support Vector Machine* dan Fitur *Term Frequency* pada RapidMiner

Gambar 8 memperlihatkan performansi akurasi metode *Support Vector Machine* dengan fitur TF-IDF yaitu sebesar 82,69%.

accuracy: 82.69%						
	true kapabilitas-positif	true integritas-positif	true integritas-negatif	true kapabilitas-negatif	true akseptabilitas-po	true akseptabilitas-neg
pred. kapabilitas-positif	66	1	0	3	2	0
pred. integritas-positif	6	36	4	2	6	3
pred. integritas-negatif	2	6	55	3	1	4
pred. kapabilitas-nega	2	1	1	42	0	3
pred. akseptabilitas-pr	4	5	0	4	95	2
pred. akseptabilitas-ni	0	1	4	3	3	69

Gambar 8 Akurasi Klasifikasi dengan Metode *Support Vector Machine* dan Fitur TF-IDF pada RapidMiner

#### 4.2.3 Perbandingan Hasil Pengujian

Perbandingan hasil perhitungan akurasi antara aplikasi yang dibangun dengan *tools* RapidMiner diperlihatkan oleh Tabel 3. Hasil menunjukkan bahwa penggunaan *term frequency* menghasilkan performansi akurasi lebih baik dari TF-IDF, baik dengan metode *Naive Bayes* maupun *Support Vector Machine*. Akurasi yang diperoleh pada aplikasi dengan *Naive Bayes* dan fitur *term frequency* memiliki selisih 2,93% dengan hasil akurasi pada RapidMiner. Adapun akurasi dengan *Naive Bayes* dan fitur TF-IDF memiliki selisih 1,81% dengan hasil akurasi pada RapidMiner.

Tabel 3 Perbandingan Hasil Perhitungan Akurasi

Metode	Fitur	Akurasi pada Aplikasi	Akurasi pada RapidMiner
<i>Naive Bayes</i>	<i>Term frequency</i>	70,88%	73,81%
	TF-IDF	69,30%	71.11%
SVM	<i>Term frequency</i>	-	83,14%
	TF-IDF	-	82,69%

## 5. KESIMPULAN

Penelitian ini telah berhasil membangun model untuk melakukan klasifikasi *tweet* berdasarkan sentimen dan kategori dengan *Naive Bayes Classifier*. Hasil akurasi pengujian klasifikasi dengan fitur *term frequency* diperoleh sebesar 70,88% sedangkan fitur TF-IDF didapatkan akurasi sebesar 69,30%. Klasifikasi menggunakan *tools* RapidMiner dengan *Naive Bayes* dan fitur *term frequency* diperoleh sebesar 73,81% sedangkan dengan fitur TF-IDF diperoleh sebesar 71.11%. Klasifikasi dengan *Support Vector Machine* menghasilkan akurasi 83,14% untuk fitur *term frequency* dan 82,69% untuk fitur TF-IDF. Hasil pengujian pada aplikasi yang dibangun dan pada *tools* RapidMiner memperlihatkan bahwa akurasi dengan fitur *term frequency* memberikan hasil akurasi yang lebih baik daripada akurasi dengan fitur TF-IDF. Metode *Support Vector Machine* menghasilkan akurasi performansi yang lebih baik daripada metode *Naive Bayes*. Penggunaan metode *Support Vector Machine* dan *Naive Bayes* sama-sama memiliki hasil akurasi yang cukup baik untuk klasifikasi *tweet*.

## DAFTAR PUSTAKA

- Aliandu, P., 2012, Analisis Sentimen Tweet Berbahasa Indonesia di Twitter, *Tesis*, Program Studi S2 Ilmu Komputer, Fakultas Matematika Dan Ilmu Pengetahuan Alam, Universitas Gadjah Mada, Yogyakarta.
- Blanco, E., dan Moldovan, D., 2011, Some Issues on Detecting Negation from Text, *Proceedings of the Twenty-Fourth International Florida Artificial Intelligence Research Society Conference*.
- Choy, M., Cheong, M. L., Laik, M. N., dan Shung, K. P., 2011, *A sentiment analysis of Singapore Presidential Election 2011 using Twitter data with census correction*, arXiv preprint arXiv:1108.5520.



- Choy, M., Cheong, M., Laik, M. N., dan Shung, K. P., 2012, *US Presidential Election 2012 Prediction using Census Corrected Twitter Model*, arXiv preprint arXiv:1211.0938.
- Go, A., Bhayani, R., dan Huang, L., 2009, *Twitter Sentiment Classification Using Distant Supervision*, CS224N Project Report, Stanford, 1-12.
- Groot, D.R., 2012, Data Mining for Tweet Sentiment Classification, *Master Thesis*, Faculty of Science Department of Information and Computing Sciences, Utrecht University.
- Hemalatha, I., Varma, P.G., dan Govardhan, A., 2012, Preprocessing the Informal Text for Efficient Sentiment Analysis, *International Journal of Emerging Trends & Technology in Computer Science (IJETTCS)*, Vol. 1, July – August 2012, ISSN 2278-6856.
- Horn, C., 2010, Analysis and Classification of Twitter Messages, *Master's Thesis*, Graz University of Technology, Austria.
- Kantardzic, M., 2003, *Data Mining: Concepts, Models, Methods, and Algorithms*, John Wiley & Sons.
- Kumar, A., dan Sebastian, T.M., 2012, Sentimen Analysis on Twitter, *IJCSI International Journal of Computer Science Issues*, Vol. 9, No 3, July 2012, ISSN (Online): 1694-0814.
- Manning, C., Raghavan, P., dan Schutze, H., 2009, *Introduction to Information Retrieval*, Cambridge University Press.
- Mujani, S., Prasetyo, H., Ambardi, K., Assaukanie, L., Muhammad, F., Abbas, S., Muhtadi, B., Syafrani, A., Endrizal, E., Marbawi, M., dan Natalie, G., 2012, *Menuju Pilpres 2014 Yang Lebih Berkualitas*, [http://www.lsi.or.id/riset/427/Rilis\\_Capres\\_Indonesia\\_2014](http://www.lsi.or.id/riset/427/Rilis_Capres_Indonesia_2014), diakses 3 Maret 2013.
- Nugroho, E., 2011, Sistem Deteksi Plagiarisme Dokumen Teks Dengan Menggunakan Algoritma Rabin-Karpi, *Skripsi*, Program Studi Ilmu Komputer, Jurusan Matematika Fakultas Matematika dan Ilmu Pengetahuan Alam, Universitas Brawijaya Malang.
- Romelta, E., 2012, Opinion Mining di Twitter untuk Customer Feedback Smartphone dengan Pembelajaran Mesin, *Jurnal Sarjana Institut Teknologi Bandung Bidang Teknik Elektro dan Informatika*, Vol. 1, No. 2, Juli 2012.
- Sang, E. T. K., dan Bos, J., 2012, Predicting The 2011 Dutch Senate Election Results with Twitter, *Proceedings of the 13th Conference of the European Chapter of the Association for Computational Linguistics*, Association for Computational Linguistics, pp. 53-60.
- Sunni, I., dan Widyantoro, D.H., 2012, Analisis Sentimen dan Ekstraksi Topik Penentu Sentimen pada Opini terhadap Tokoh Publik, *Jurnal Sarjana Institut Teknologi Bandung Bidang Teknik Elektro dan Informatika*, Vol. 1, No. 2, Juli 2012.
- Yamamoto, M., dan Church, K.W., 2001, Using Suffix Arrays to Compute Term Frequency and Document Frequency for All Substrings in A Corpus, *Computational Linguistics*, 27(1), 1-30.